UC 2A - LE MACHINE LEARNING EN PRATIQUE

INTRODUCTION AUX OUTILS (NUMPY, SCIKIT-LEARN...)

Vincent Guigue, Romain Thoreau
vincent.guigue@agroparistech.fr

Intelligence Artificielle, Machine Learning et Programmation

Input (**X**)		Output (**Y**)	Application
email	→	spam? (0/1)	spam filtering
audio	→	text transcript	speech recognition
English	→	Chinese	machine translation
ad, user info	→	click? (0/1)	online advertising
image, radar info	→	position of other cars	self-driving car
image of phone	→	defect? (0/1)	visual inspection

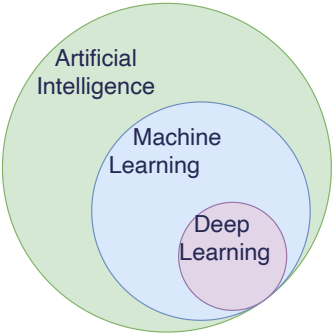

IA : programmes informatiques qui s'adonnent à des tâches qui sont, pour l'instant, accomplies de façon plus satisfaisante par des êtres humains car elles demandent des processus mentaux de haut niveau.

Marvin Lee Minsky, 1956

N-AI (Narrow Artificial Intelligence), dédiée à une tâche

$\neq$ **G-AI (General AI)** qui remplace l'humain dans des systèmes complexes.

Andrew Ng, 2015

Ingrédients de l'Intelligence Artificielle

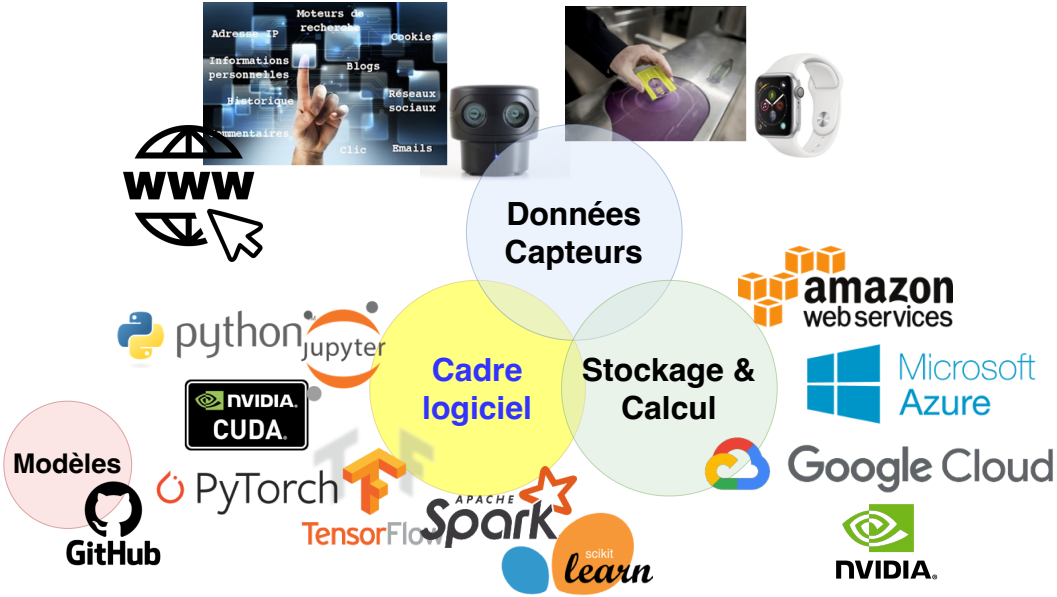

Enseignement de l'IA

- Différents niveaux d'accès
- Différentes branches: types d'outils, application thématiques, ...

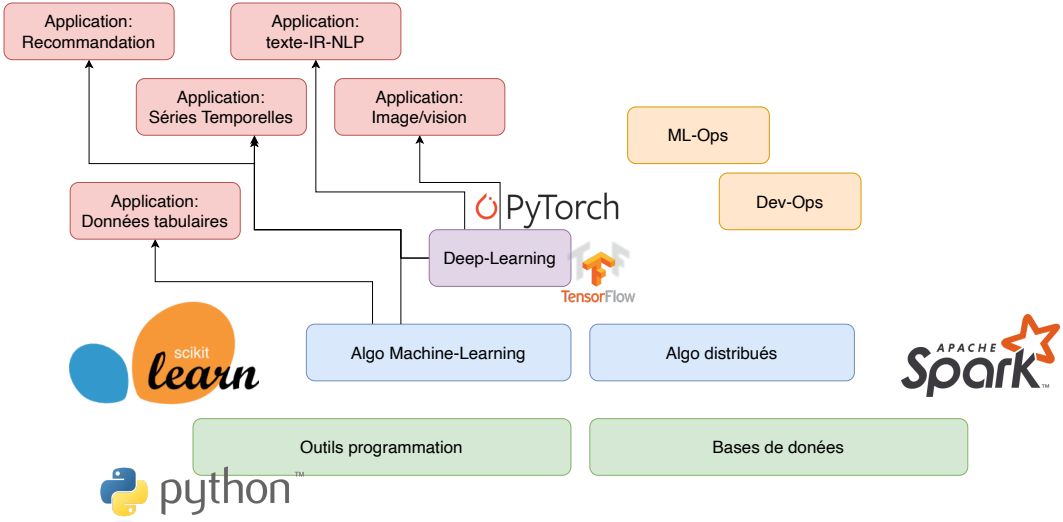

Programmation *orientée données*

- **Python** : langage unificateur (codage *vs* wrapper)
  - *Calcul scientifique* : `numpy`
  - *Machine-learning*: `scikit-learn`, `pandas`, `matplotlib`
  - *Deep-learning*: `pytorch`
  - Environnement de développement: Visual Studio Code / jupyter-notebook

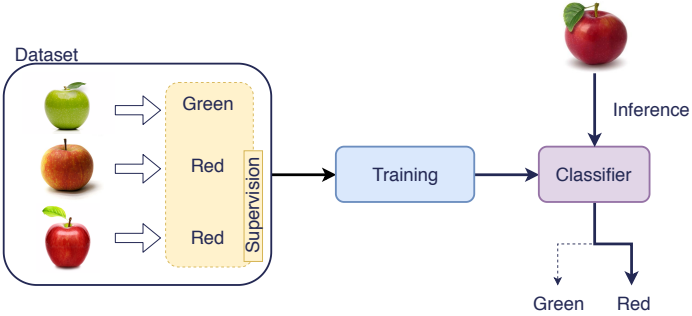

Où se trouve les leviers de performance?

Dans les modèles...
Mais surtout dans les chaînes de traitements !

Programmation *orientée données*

- **Python** : langage unificateur (codage *vs* wrapper)
  - *Calcul scientifique* : `numpy`
  - *Machine-learning*: `scikit-learn`, `pandas`, `matplotlib`
  - *Deep-learning*: `pytorch`
  - Environnement de développement: Visual Studio Code / jupyter-notebook

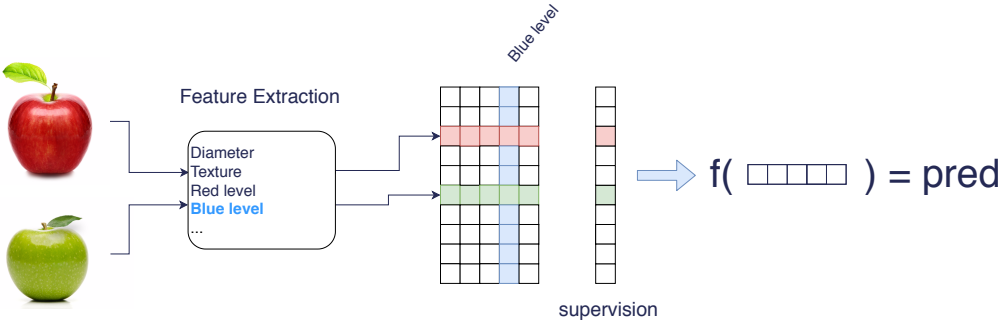

Programmation *orientée données*

- **Python** : langage unificateur (codage *vs* wrapper)
  - *Calcul scientifique* : `numpy`
  - *Machine-learning*: `scikit-learn`, `pandas`, `matplotlib`
  - *Deep-learning*: `pytorch`
  - Environnement de développement: Visual Studio Code / jupyter-notebook

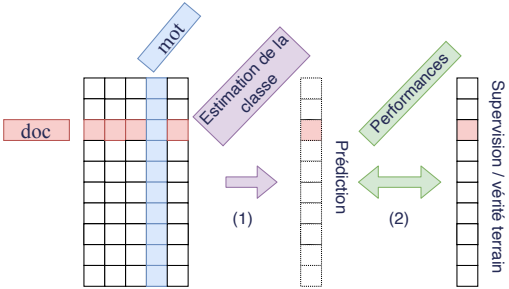

Organisation

Organisation

- **2 séances - Numpy (=5h)**
  - Mise à niveau en python, `numpy`, `matplotlib`
  - Naïve Bayes (à la main)
- **6 séances - Scikit-Learn (=6x3h30)**
  - Classifieurs Scikit-Learn : syntaxe, possibilités offertes
  - Apprentissage supervisé et non-supervisé
  - Évaluation
  - Chaine de traitements, sélection de modèles (grid-search...)
  - Visualisation & post-traitements
- **6 séances - Bouclage & projet (≈5.5x3h30)**

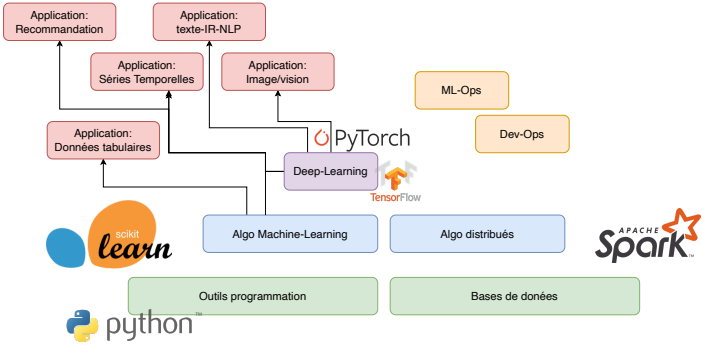

Jupyter Notebook

- Du code dans un navigateur web????
  - Principe de textes à trous
  - Bel outil pédagogique...
  - ... avec des risques (contemplation)

et des limites (organisation de code sous-optimale)

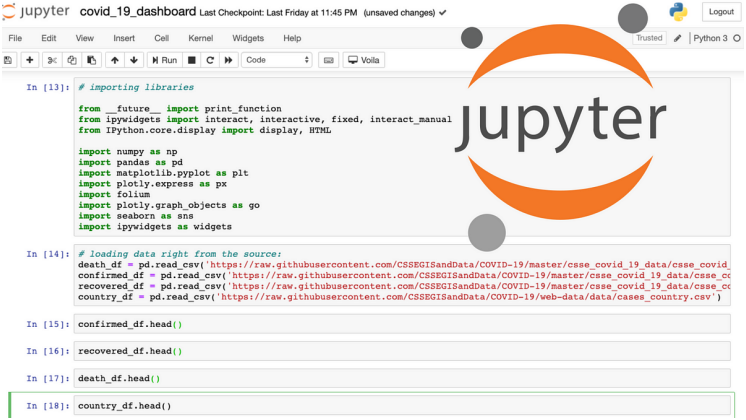

Conclusion : passer à un nouveau langage...

- **Cout faible**
  - une fois que vous avez compris la logique générale
- **Cout non négligeable:**
  - Comprendre les forces et les faiblesses du langage
    - ... Et des environnements de développement
  - Adapter sa manière de programmer (e.g. calculer un décile)
  - Reprendre les bons reflexes (=aller vite)

⇒ Devenir *data-scientist* n'a jamais été aussi facile... Mais il reste quelques savoir-faire et quelques pièges à éviter!

Programme de la première séance

Télécharger le répertoire ML-2A sur Github : `https://github.com/vguigue/ML-2A`

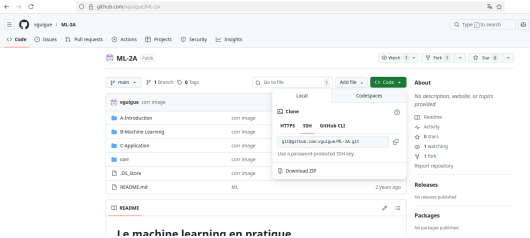

Notebooks à faire :

- 1-Python/notebooks/1_Tuto_python.ipynb : découvrir l'environnement Jupyter Notebook,
- 2-numpy/notebooks/1_Tutoriel_numpy_creation_matrice.ipynb : manipuler des matrices avec Numpy,
- 2-numpy/notebooks/4_Affichage_matplotlib.ipynb : visualiser ses résultats avec Matplotlib.